

StuntCare AI: Deteksi Dini Risiko Stunting Balita Multi-Faktor Berbasis Random Forest dengan Inferensi di Peramban

Daniel Steffen K¹⁾

¹⁾Program Studi Computer Science, BINUS University, Jakarta

Penulis korespondensi: daniel.k@binus.ac.id · NIM 2602071171 · Kelas LA05-LEC

ABSTRAK

Stunting masih menjadi masalah gizi kronis utama di Indonesia dengan prevalensi 19,8% (SSGI 2024) dan disebabkan banyak faktor yang saling terkait, bukan hanya tinggi badan. Tujuan kajian ini adalah membangun aplikasi deteksi dini risiko stunting yang menganalisis tujuh faktor penyebab sekaligus dan mudah diakses masyarakat. Metode yang digunakan adalah klasifikasi **Random Forest** (ensemble 120 pohon keputusan) yang dilatih pada 25.000 sampel data anak dan ibu, lalu dikemas menjadi aplikasi web statis. Untuk kebutuhan deployment dan privasi, model scikit-learn dikonversi ke format ONNX dan dijalankan sepenuhnya di peramban pengguna (on-device) memakai ONNX Runtime Web di dalam Web Worker. Hasil pengujian menunjukkan akurasi 88,40%, F1-score makro 83,56%, validasi silang $87,31\% \pm 0,42\%$, serta disparitas antar gender 1,83% (di bawah ambang 5%). Aplikasi berjalan cepat, gratis, dapat luring, dan data tidak dikirim ke server. Disimpulkan bahwa pendekatan ini layak sebagai alat skrining awal yang akurat dan menjunjung privasi, mendukung SDG #3 Good Health and Well-being.

Kata kunci: stunting, Random Forest, machine learning, inferensi di peramban, ONNX, WHO Child Growth Standards.

ABSTRACT

Stunting remains a major chronic malnutrition problem in Indonesia (19.8% prevalence, SSGI 2024) and is driven by many interrelated factors, not height alone. This work builds an early stunting-risk screening application that jointly analyses seven causal factors and is easy for the public to access. We use a **Random Forest** classifier (an ensemble of 120 decision trees) trained on 25,000 child-and-mother records, packaged as a static web application. For deployment and privacy, the scikit-learn model is converted to ONNX and runs entirely in the user's browser (on-device) via ONNX Runtime Web inside a Web Worker. The model reaches 88.40% accuracy, 83.56% macro F1, $87.31\% \pm 0.42\%$ cross-validation, and a 1.83% gender disparity (below the 5% threshold). The app is fast, free, offline-capable, and sends no data to any server, making it a feasible, privacy-preserving screening tool that supports SDG #3.

Keywords: stunting, Random Forest, machine learning, in-browser inference, ONNX, WHO Child Growth Standards.

Pendahuluan

Permasalahan utama pada kajian ini adalah bahwa stunting dapat dipengaruhi oleh **banyak faktor yang saling terkait** tidak hanya tinggi badan anak. Namun, faktor maternal seperti jarak kehamilan yang terlalu dekat (program 4 Terlalu BKKBN), pernikahan dini, dan status gizi ibu saat hamil (risiko Kurang Energi Kronis/KEK yang berujung Berat Badan Lahir Rendah/BBLR) turut berkontribusi. Maka dari itu, solusi skrining yang ada di lapangan umumnya masih manual (pengukuran posyandu) dan menilai satu indikator saja, sehingga belum dapat mengintegrasikan banyak faktor secara cepat dan objektif.

Fokus kajian ini adalah membangun sistem prediksi berbasis *machine learning* yang menggabungkan **tujuh faktor** penyebab stunting menjadi satu prediksi terpadu, serta menjadikannya aplikasi web yang ringan, gratis, dan menjaga privasi data anak. Kontribusi utama meliputi: (1) model Random Forest tujuh fitur dengan akurasi 88,40%; (2) arsitektur inferensi yang berjalan 100% di perangkat pengguna; dan (3) modul opsional analisis foto untuk memperkirakan proporsi tubuh secara eksperimental dan transparan.

Metode

1. Dataset dan Praproses

Kajian menggunakan dataset 25.000 sampel berisi tujuh fitur masukan dan satu label status gizi dengan empat kelas: *Normal*, *Stunted*, *Severely Stunted*, dan *Tinggi*. Variabel kategorikal (jenis kelamin dan gizi ibu) dikodekan dengan *Label Encoding*. Data dibagi menjadi 80% latih (20.000) dan 20% uji (5.000) secara acak terstratifikasi. Tujuh fitur masukan ditunjukkan pada Tabel 1.

No	Fitur	Tipe	Keterangan
1	Umur (bulan)	Numerik	0–60 bulan, acuan standar WHO
2	Jenis Kelamin	Kategorikal	Laki-laki / Perempuan
3	Tinggi Badan (cm)	Numerik	Indikator utama (HAZ)
4	Berat Badan (kg)	Numerik	Indikator Weight-for-Age
5	Jarak Kehamilan (bln)	Numerik	Ideal >24 bln (BKKBN 4T)
6	Usia Ibu Menikah (thn)	Numerik	Dini <20 thn = risiko
7	Gizi Ibu Saat Hamil	Kategorikal	Baik / Sedang / Buruk

Tabel 1. Tujuh faktor masukan model.

2. Algoritma Random Forest

Algoritma inti adalah **Random Forest Classifier** (Breiman, 2001), yaitu *ensemble* dari banyak pohon keputusan (*decision tree*) yang dilatih dengan teknik *bootstrap aggregating* (bagging). Setiap pohon dilatih pada subsampel data yang diambil acak dengan pengembalian, dan pada setiap percabangan hanya sebagian fitur yang dipertimbangkan secara acak. Prediksi akhir diperoleh dengan merata-ratakan distribusi probabilitas seluruh pohon (*soft voting*), sehingga menghasilkan klasifikasi yang akurat dan stabil terhadap *overfitting*.

Random Forest dipilih karena beberapa alasan teknis yaitu, (1) tahan terhadap *overfitting* melalui rata-rata banyak pohon; (2) menangani campuran fitur numerik dan kategorikal tanpa perlu penskalaan; (3) menyediakan *feature importance* sehingga model dapat ditafsirkan (penting untuk transparansi di ranah kesehatan); dan (4) cepat saat inferensi. Konfigurasi model ditunjukkan pada Tabel 2.

Parameter	Nilai	Parameter	Nilai
Algoritma	Random Forest	Jumlah pohon	120 trees
Kedalaman maks.	14 level	Jumlah fitur	7
Data latih	20.000 (80%)	Data uji	5.000 (20%)
Library	scikit-learn 1.9	Voting	Soft (rata-rata proba)

Tabel 2. Konfigurasi model Random Forest.

Kutipan inti pelatihan model (Python, scikit-learn):

```
from sklearn.ensemble import RandomForestClassifier
rf = RandomForestClassifier(n_estimators=120, max_depth=14,
                           random_state=42, n_jobs=-1)
rf.fit(X_train, y_train) # 7 fitur -> 4 kelas status gizi proba =
rf.predict_proba(X_test) # distribusi probabilitas tiap kelas
```

3. Rekayasa Perangkat Lunak: dari Streamlit ke Web Statis + ONNX

Purwarupa awal dibangun dengan **Streamlit** (Python). Meskipun fungsional, pendekatan ini memiliki dua kelemahan yaitu, pada tampilan saat demo terbatas, dan yang paling krusial pada Streamlit, karena membutuhkan *server* Python sehingga **tidak dapat di deploy pada Cloudflare Pages** yang bersifat statis. Oleh karena itu aplikasi dibangun ulang sebagai web statis modern dengan tetap mempertahankan model 88,40% yang sama.

Langkah-langkah migrasi:

- **Konversi model:** model *.pkl* scikit-learn diubah ke **ONNX** memakai *skl2onnx*; kesetaraan hasil (parity) diverifikasi terhadap scikit-learn dengan galat maksimum hanya $3,4 \times 10^{-4}$ dan nol perbedaan kelas pada 3.000 sampel acak.
- **Frontend baru:** React + Vite + TypeScript + Tailwind CSS dengan komponen bergaya shadcn/ui; empat tab (Deteksi, Tentang, Cara Kerja AI, Etika & Privasi).
- **Inferensi di peramban:** ONNX Runtime Web (WebAssembly) menjalankan model langsung di perangkat pengguna, dijalankan di dalam **Web Worker** agar utas utama tidak membeku (memperbaiki dialog “Page Unresponsive” pada versi sebelumnya). WASM dipaksa *single-thread* sehingga tidak memerlukan header COOP/COEP dan tetap mudah di-deploy.
- **Privasi & luring:** seluruh perhitungan terjadi di perangkat; data anak tidak dikirim ke server, dan aplikasi dapat berjalan luring setelah pemuatan pertama.

Kutipan inti inferensi di peramban (TypeScript, di dalam Web Worker):

```
import * as ort from "onnxruntime-web/wasm";
const session = await ort.InferenceSession.create(modelUrl);
const x = new ort.Tensor("float32", Float32Array.from(fitur7), [1, 7]);
const out = await session.run({ input: x });
const probabilitas = Array.from(out["probabilities"].data); // 4 kelas
```

4. Modul Opsional Analisis Foto (Eksperimental)

Sebagai pengayaan, ditambahkan modul opsional yang memperkirakan **proporsi tubuh** (kurus/normal/gemuk) dari foto memakai MediaPipe Pose (33 titik tubuh) beserta *segmentation mask*. Karena stunting adalah masalah tinggi-untuk-umur yang tidak dapat diukur dari foto 2D, sinyal foto **tidak** dijadikan fitur Random Forest (yang akan memerlukan pelatihan ulang berdata-foto). Sebaliknya, digunakan *late-fusion* yang transparan: ketebalan tiap anggota tubuh diukur dari siluet lalu dinormalisasi terhadap panjang tulang (bersifat *scale-* dan *pose-invariant*), kemudian hanya menggeser probabilitas akhir secara terbatas (maksimum ± 10 poin) dengan menampilkan nilai sebelum → sesudah.

Hasil dan Pembahasan

1. Performa Model


Model dievaluasi pada 5.000 sampel uji. Tabel 3 merangkum metrik yang dicapai. Akurasi 88,40% melampaui ambang “Excellent” ($\geq 85\%$) pada rubrik penilaian.

Metrik	Skor	Metrik	Skor
Accuracy	88,40%	Recall (macro)	85,93%
Precision (macro)	81,59%	F1-Score (macro)	83,56%
Cross-Validation (5-fold)	87,31% $\pm$ 0,42%	Disparitas gender	1,83%


Tabel 3. Ringkasan performa model pada data uji.

2. Matriks Konfusi dan Kepentingan Fitur

Gambar 1 menampilkan matriks konfusi yaitu, kesalahan klasifikasi sebagian besar terjadi antar kelas bertetangga (mis. *Stunted* vs *Severely Stunted*), yang wajar karena batasnya kontinu. Lalu, pada Gambar 2 menunjukkan bahwa **tinggi badan (50,6%)** dan **umur (28,7%)** mendominasi kepentingan fitur konsisten dengan definisi HAZ, sementara faktor maternal berkontribusi lebih kecil namun tetap bermakna untuk konteks risiko.



Gambar 1 (kiri). Matriks konfusi. Gambar 2 (kanan). Feature importance 7 faktor.



Gambar 3. Eksplorasi distribusi data (EDA).

3. Keadilan (Fairness) dan Etika

Audit keadilan antar gender menghasilkan disparitas akurasi 1,83% (laki-laki 89,30% vs perempuan 87,46%) di bawah ambang industri 5%. Aplikasi juga menampilkan *confidence score*, probabilitas tiap kelas, Z-Score WHO, dan catatan faktor risiko, sehingga bersifat transparan dan tidak menjadi “kotak hitam”. Disclaimer medis ditampilkan jelas yaitu, hasil tersebut merupakan skrining awal, bukan diagnosis.

4. Hasil Rebuild dan Inferensi di Peramban

Migrasi berhasil mempertahankan akurasi identik sekaligus memperbaiki keterbatasan deployment. Tabel 4 merangkum karakteristik aplikasi hasil rebuild.

Aspek	Hasil
Akurasi vs scikit-learn (ONNX)	Identik (galat maks. $3,4 \times 10^{-4}$)
Transfer pertama (gzip)	± 5 MB (model + runtime), di-cache setelahnya
Waktu inferensi	Mikrodetik; berjalan di Web Worker (UI tidak membeku)
Privasi	100% di perangkat; data tidak dikirim ke server
Deployment	Cloudflare Pages (statis, gratis); dapat luring

Tabel 4. Karakteristik aplikasi hasil rebuild.

Modul analisis foto diuji unit pada tubuh sintetis kurus/normal/gemuk dan terbukti membedakan ketiganya secara monoton serta tak bergantung posisi (berdiri, duduk, berbaring). Temuan ini menegaskan kelayakan pendekatan *late-fusion* yang jujur, sekaligus mengakui keterbatasannya (foto 2D tidak mengukur tinggi absolut).

Kesimpulan

Kajian ini berhasil membangun StuntCare AI yang di mana aplikasi ini dapat mendeteksi secara dini risiko dari stunting multi faktor berbasis Random Forest dengan akurasi 88,40% (kategori Excellent), F1-score makro 83,56%, dan disparitas gender 1,83%. Inovasi utamanya adalah untuk menjalankan model asli sepenuhnya di peramban pengguna melalui konversi ke ONNX, sehingga aplikasi dapat digunakan secara gratis, cepat, luring, dan tetap menjaga privasi data dari anak-anak yang mengatasi keterbatasan purwarupa *Streamlit* yang memerlukan server. Secara umum, pendekatan ini layak untuk diterapkan sebagai alat skrining awal yang akurat, transparan, dan mudah diakses untuk mendukung penurunan prevalensi stunting (SDG #3). Pengembangan lanjutan mencakup validasi klinis modul foto dan kalibrasi ambang proporsi tubuh dengan data berlabel nyata.

Ucapan Terima Kasih

Saya mengucapkan terima kasih kepada dosen pengampu mata kuliah Artificial Intelligence (COMP6065001) dan BINUS University atas bimbingan dan dukungannya selama penyusunan proyek Saya ini.

Kontribusi Penulis

Proyek ini Saya kerjakan secara individu dan Saya juga bertanggung jawab penuh atas keseluruhan tahap yaitu, perumusan masalah dan studi literatur, penyiapan dataset, pelatihan dan evaluasi model Random Forest, pengembangan purwarupa *Streamlit*, pembangunan ulang aplikasi web (React + Vite + ONNX Runtime Web), pengembangan modul analisis foto, deployment, serta penulisan laporan dan bahan presentasi.

Daftar Pustaka

[1] Breiman, L. 2001. Random Forests. *Machine Learning*, 45(1): 5–32.

- [2] World Health Organization. 2006. WHO Child Growth Standards: Length/height-for-age, weight-for-age. Geneva: WHO.
- [3] Apriluana, G. dan Fikawati, S. 2018. Analisis Faktor-Faktor Risiko terhadap Kejadian Stunting pada Balita. *Media Litbangkes*, 28(4): 247–256.
- [4] Kementerian Kesehatan RI. 2024. Survei Status Gizi Indonesia (SSGI) 2024. Jakarta: Badan Kebijakan Pembangunan Kesehatan, Kemenkes RI.
- [5] Badan Kependudukan dan Keluarga Berencana Nasional (BKKBN). 2017. Program “4 Terlalu” dalam Pencegahan Risiko Kehamilan dan Stunting. Jakarta: BKKBN.
- [6] Bazarevsky, V., Grishchenko, I., Raveendran, K., dkk. 2020. BlazePose: On-device Real-time Body Pose Tracking. *arXiv:2006.10204*.
- [7] ONNX Runtime Developers. 2024. ONNX Runtime Web: Run ONNX models in the browser. URL: <https://onnxruntime.ai/docs/tutorials/web/> (diakses 2026).