

StuntCare AI: Deteksi Dini Risiko Stunting Balita Berbasis Random Forest dengan Validasi Dataset Nyata dan Inferensi di Peramban

Daniel Steffen K¹⁾

¹Program Studi Computer Science, BINUS University, Jakarta

Penulis korespondensi: daniel.k@binus.ac.id · NIM 2602071171 · Kelas LA05-LEC

ABSTRAK

Stunting masih menjadi masalah gizi kronis utama di Indonesia dengan prevalensi 21,5% (SKI/SSGI 2023) — sekitar satu dari lima balita — dan masih jauh dari target nasional 14% (Perpres 72/2021). Kajian ini membangun aplikasi deteksi dini risiko stunting menggunakan algoritma **Random Forest**. Model divalidasi pada **dataset stunting balita nyata Indonesia** sebanyak 55.367 sampel (berbasis WHO Child Growth Standards) dan mencapai akurasi 99.39%, F1-score makro 99.4%, serta validasi silang $99.18\% \pm 0.12\%$, mengungguli Decision Tree, KNN, Regresi Logistik, dan Naive Bayes pada benchmark. Sebagai pengembangan, dibangun pula prototipe multi-faktor (7 faktor anak dan maternal) untuk mengintegrasikan faktor risiko dari literatur. Model dikemas menjadi aplikasi web yang menjalankan inferensi 100% di peramban pengguna (ONNX Runtime Web), sehingga gratis, cepat, dapat luring, dan menjaga privasi. Disimpulkan bahwa pendekatan ini layak dan akurat sebagai alat skrining awal untuk mendukung SDG #3.

Kata kunci: stunting, Random Forest, dataset nyata, WHO Child Growth Standards, inferensi di peramban, SDG #3.

ABSTRACT

Stunting remains a major chronic malnutrition problem in Indonesia (21.5% prevalence, SKI 2023). This work builds an early stunting-risk screening application using a **Random Forest** classifier. The model is validated on a **real Indonesian toddler stunting dataset** of 55,367 samples (WHO-based), reaching 99.39% accuracy, 99.4% macro F1, and $99.18\% \pm 0.12\%$ cross-validation, outperforming Decision Tree, KNN, Logistic Regression, and Naive Bayes. A multi-factor prototype (seven child and maternal factors) extends the approach with literature-based risk factors. The model runs entirely in the user's browser via ONNX Runtime Web — free, fast, offline-capable, and privacy-preserving — supporting SDG #3.

Keywords: stunting, Random Forest, real dataset, WHO Child Growth Standards, in-browser inference, SDG #3.

Pendahuluan

Stunting adalah gangguan pertumbuhan akibat kekurangan gizi kronis yang ditandai tinggi badan menurut umur (Height-for-Age Z-Score/HAZ) di bawah -2 SD menurut WHO Child Growth Standards (2006). Berdasarkan Survei Kesehatan Indonesia (SKI/SSGI) 2023, prevalensi stunting nasional sebesar **21,5%** — turun tipis dari 21,6% (2022) namun masih jauh di atas **target nasional 14%** pada 2024 (Perpres No. 72 Tahun 2021) dan ambang WHO 20%. Riskesdas 2018 bahkan mencatat 30,8%. Artinya sekitar **satu dari lima balita** Indonesia (jutaan anak) masih berisiko.

Kebutuhan nyata. Dampak stunting bersifat permanen dan lintas generasi: gangguan perkembangan kognitif (penurunan IQ), daya tahan tubuh lemah, prestasi belajar rendah, hingga menurunnya produktivitas dan pendapatan saat dewasa (diperkirakan 10–20% lebih rendah). Bank Dunia dan Bappenas memperkirakan kerugian ekonomi akibat stunting mencapai **2–3% PDB per tahun**. Karena periode kritis hanya pada **1000 Hari Pertama Kehidupan**, keterlambatan deteksi sangat merugikan.

Kesenjangan yang nyata. Skrining di lapangan umumnya masih manual di posyandu, menilai satu indikator, dan rentan kekurangan tenaga gizi—terutama di daerah tertinggal, terdepan, dan terluar (3T) dengan akses internet terbatas. Belum tersedia alat bantu yang murah, cepat, dapat dipakai

luring, dan menjaga privasi. **Kebutuhan akan alat skrining dini yang akurat, gratis, dan mudah diakses sangat nyata namun belum terpenuhi.**

Pengaplikasian nyata. Sistem ini ditujukan untuk: (1) orang tua balita — skrining mandiri di rumah, bahkan tanpa internet; (2) kader posyandu — skrining cepat dan prioritas rujukan; (3) puskesmas/dinas kesehatan — deteksi dini dan penentuan sasaran intervensi. Fokus kajian adalah membangun model Random Forest yang divalidasi pada data nyata Indonesia, lalu menjadikannya aplikasi web ringan yang berjalan di perangkat pengguna.

Metode

1. Sumber Data dan Dataset

Digunakan dua sumber data. **(a) Dataset nyata** — "Stunting Toddler (Balita) Detection" berbasis kondisi anak Indonesia dan WHO Child Growth Standards, sebanyak **55.367 sampel** dengan fitur Umur (bulan), Jenis Kelamin, dan Tinggi Badan (cm) serta label Status Gizi empat kelas. Dataset ini dipakai untuk **melatih dan memvalidasi** model inti pada kondisi data riil. **(b) Dataset multi-faktor** — disusun mengacu WHO 2006 dan literatur (SSGI, BKKBN) untuk prototipe 7 faktor (menambah berat badan dan faktor maternal: jarak kehamilan, usia ibu menikah, gizi ibu saat hamil) karena faktor maternal belum tersedia pada dataset publik. Kedua sumber dinyatakan terbuka demi transparansi.

Aspek	Dataset Nyata (validasi)	Dataset Multi-Faktor (prototipe)
Jumlah	55.367 sampel	25.000 sampel
Fitur	3 (umur, kelamin, tinggi)	7 (anak + maternal)
Kelas	Normal, Stunted, Sev. Stunted, Tinggi	sama (4 kelas)
Sumber	Kaggle/GitHub, basis WHO	WHO 2006 + literatur

Tabel 1. Dua sumber data yang digunakan.

2. Algoritma Random Forest — Penjelasan Matematis

Random Forest (Breiman, 2001) adalah *ensemble* dari T pohon keputusan yang dilatih dengan *bootstrap aggregating* (bagging). Tiap pohon ke- t dilatih pada sampel *bootstrap* D_t (penarikan acak dengan pengembalian dari data latih), dan pada setiap simpul hanya dipertimbangkan subset acak m fitur (umumnya $m = \sqrt{p}$, dengan p jumlah fitur). Pemilihan split memaksimalkan penurunan ketidakmurnian (impurity).

Ketidakmurnian Gini pada simpul t (C kelas, p_i proporsi kelas i):

$$Gini(t) = 1 - \sum_{i=1..C} p_i^2$$

Penurunan ketidakmurnian saat simpul dipecah menjadi anak kiri (L) dan kanan (R):

$$\Delta I = Gini(t) - (N_L/N_t) \cdot Gini(L) - (N_R/N_t) \cdot Gini(R)$$

Prediksi akhir memakai rata-rata probabilitas seluruh pohon (*soft voting*); $P_t(c|x)$ adalah proporsi kelas c pada daun yang dicapai x di pohon t :

$$P(c|x) = (1/T) \sum_{t=1..T} P_t(c|x) ; \blacksquare = \arg \max_c P(c|x)$$

Kepentingan fitur (*Mean Decrease in Impurity*) — total penurunan impurity yang disumbang fitur f di seluruh simpul dan pohon, lalu dinormalkan:

$$Imp(f) = (1/T) \sum_t \sum_{v \in t: \text{split}(v)=f} (N_v/N) \cdot \Delta I_v$$

Random Forest dipilih karena tahan *overfitting* (rata-rata banyak pohon), menangani fitur numerik dan kategorikal tanpa penskalaan, cepat saat inferensi, dan memberikan kepentingan fitur sehingga model dapat ditafsirkan (penting di ranah kesehatan).

3. Z-Score WHO (HAZ) dan Metrik Evaluasi

Status gizi mengacu Z-score tinggi-untuk-umur; X tinggi anak, M median WHO, S standar deviasi untuk usia dan jenis kelamin yang sama:

$$HAZ = (X - M) / S \rightarrow HAZ < -3: \text{Severely Stunted}; -3..-2: \text{Stunted}; -2..+2: \text{Normal}; > +2: \text{Tinggi}$$

Kinerja diukur dengan (TP/TN/FP/FN per kelas):

$$Akurasi = (TP+TN)/Total ; Precision = TP/(TP+FP) ; Recall = TP/(TP+FN) ; F1 = 2 \cdot P \cdot R / (P+R)$$

Nilai *macro* adalah rata-rata metrik antar kelas (memberi bobot sama pada tiap kelas), dan validasi silang 5-fold menguji kestabilan model.

4. Tahapan Pembuatan & Pelatihan (Step-by-step)

Proses pelatihan model dilakukan berurutan sebagai berikut:

1) **Pengumpulan data** (dataset nyata 55.367 + dataset multi-faktor 25.000). 2) **Pembersihan & penyeragaman label** menjadi 4 kelas. 3) **Encoding** variabel kategorikal dengan *Label Encoding* (lihat Tabel 2). 4) **Pembagian data** 80% latih : 20% uji secara *stratified*. 5) **Inisialisasi** Random Forest (Tabel 3). 6) **Pelatihan**: tiap pohon dibangun dari sampel bootstrap dengan subset fitur acak, tumbuh hingga batas kedalaman/sampel daun. 7) **Validasi silang** 5-fold pada data latih. 8) **Evaluasi** pada data uji (akurasi, precision, recall, F1, confusion matrix). 9) **Analisis kepentingan fitur**. 10) **Konversi** model ke format **ONNX** agar dapat berjalan di peramban. 11) **Integrasi** ke aplikasi web React (inferensi di Web Worker).

Variabel	Pemetaan Label Encoding
Jenis Kelamin	laki-laki → 0 ; perempuan → 1
Gizi Ibu (prototipe)	Baik → 0 ; Buruk → 1 ; Sedang → 2
Status Gizi (label)	Normal → 0 ; Severely Stunted → 1 ; Stunted → 2 ; Tinggi → 3

Tabel 2. Encoding variabel kategorikal.

Parameter	Nilai	Parameter	Nilai
n_estimators	120 pohon	max_features	sqrt
max_depth	14	class_weight	balanced
min_samples_leaf	6	min_samples_split	12
random_state	42	library	scikit-learn

Tabel 3. Hiperparameter Random Forest.

Kutipan inti kode pelatihan (Python, scikit-learn):

```
from sklearn.ensemble import RandomForestClassifier
rf = RandomForestClassifier(n_estimators=120, max_depth=14,
                           min_samples_leaf=6, min_samples_split=12, max_features='sqrt',
                           class_weight='balanced', random_state=42, n_jobs=-1)
rf.fit(X_train, y_train)          # bagging 120 pohon
proba = rf.predict_proba(X_test)  # soft voting -> probabilitas
```


5. Rekayasa Aplikasi Web (Inferensi di Peramban)

Model `.pkl` dikonversi ke **ONNX** (skl2onnx; kesetaraan hasil terverifikasi dengan galat maksimum $3,4 \times 10^{-4}$). Aplikasi dibangun dengan **React + Vite + TypeScript + Tailwind CSS**; inferensi dijalankan oleh **ONNX Runtime Web (WebAssembly)** di dalam **Web Worker** agar antarmuka tidak membeku. Seluruh perhitungan terjadi di perangkat pengguna sehingga aplikasi gratis, cepat, dapat luring, dan data tidak dikirim ke server. Ditambahkan pula asisten edukasi tanya-jawab tentang pencegahan stunting.


Hasil dan Pembahasan

1. Validasi pada Dataset Nyata Indonesia

Model dilatih pada 44.293 sampel dan diuji pada 11.074 sampel data nyata. Random Forest mencapai **akurasi 99.39%**, precision makro 99.39%, recall makro 99.41%, F1-score makro 99.4%, dan validasi silang 5-fold $99.18\% \pm 0.12\%$. Distribusi kelas dataset relatif seimbang (Gambar 1), sehingga metrik tidak bias.




Gambar 1. Distribusi kelas pada dataset nyata (55.367 sampel).



Gambar 2 (kiri). Confusion matrix model pada data uji nyata. Gambar 3 (kanan). Kepentingan fitur (data nyata).

Confusion matrix (Gambar 2) menunjukkan kesalahan klasifikasi sangat kecil dan hanya terjadi pada batas antar kelas bertetangga. Kepentingan fitur (Gambar 3) menempatkan **tinggi badan** dan **umur** sebagai faktor dominan — konsisten dengan definisi HAZ. Metrik per kelas saat pengujian disajikan pada Gambar 4.




Gambar 4. Precision, recall, dan F1-score per kelas saat pengujian alat.

2. Benchmarking Algoritma

Algoritma	Akurasi (%)	F1-Score Makro (%)
Random Forest	99.39	99.4
K-Nearest Neighbors	98.93	98.93
Decision Tree	98.86	98.86
Regresi Logistik	75.56	75.56
Naive Bayes	42.87	40.9

Tabel 4. Perbandingan algoritma pada dataset nyata.




Gambar 5. Benchmarking algoritma — Random Forest unggul.

Random Forest mengungguli seluruh pembandingan, mengonfirmasi pemilihan algoritma. Decision Tree dan KNN mendekati namun lebih rendah; Regresi Logistik (model linier) tidak mampu menangkap batas keputusan non-linier WHO; Naive Bayes terburuk karena asumsi independensi antar fitur tidak terpenuhi.

3. Prototipe Multi-Faktor (7 Faktor)

Sebagai pengembangan, model 7 faktor (menambah berat badan dan faktor maternal) mencapai akurasi 88,40%, F1 makro 83,56%, dan cross-validation $87,31\% \pm 0,42\%$. Akurasinya lebih rendah dari model inti karena memasukkan faktor risiko maternal yang menambah keragaman; model ini menjadi dasar fitur interaktif aplikasi. Confusion matrix dan kepentingan fiturnya ditunjukkan pada Gambar 6.



Gambar 6. Prototipe 7-faktor: confusion matrix (kiri) & feature importance (kanan).

Seluruh model dijalankan di peramban via ONNX (kesetaraan hasil galat $< 1 \times 10^{-4}$), waktu inferensi mikrodetik, tanpa server, dan data tidak meninggalkan perangkat — mendukung privasi sekaligus aksesibilitas.

Kesimpulan

Kajian ini membangun StuntCare AI berbasis Random Forest yang divalidasi pada **dataset stunting balita nyata Indonesia** (55.367 sampel) dengan akurasi 99.39% dan mengungguli algoritma pembandingan, membuktikan pendekatan bekerja pada kondisi data riil. Model dijalankan sepenuhnya di peramban melalui konversi ONNX sehingga gratis, cepat, dapat luring, dan menjaga privasi. Dengan kebutuhan nyata yang mendesak (prevalensi 21,5%, target 14%, kerugian ekonomi 2–3% PDB) serta keterbatasan akses skrining, aplikasi ini layak sebagai alat skrining awal yang akurat dan mudah diakses untuk mendukung SDG #3. Pengembangan lanjutan: melengkapi data faktor maternal nyata dan validasi klinis lapangan.

Ucapan Terima Kasih

Penulis berterima kasih kepada dosen pengampu mata kuliah Artificial Intelligence (COMP6065001) dan BINUS University atas bimbingan dalam penyusunan proyek ini, serta kepada penyedia dataset publik yang menjadi dasar validasi.

Kontribusi Penulis

Proyek dikerjakan secara individu oleh **Daniel Steffen K (NIM 2602071171)**: perumusan masalah dan studi literatur, pengumpulan & validasi dataset nyata, pelatihan dan evaluasi model Random Forest, benchmarking, pembangunan aplikasi web (React + ONNX Runtime Web), serta penulisan laporan dan bahan presentasi.

Daftar Pustaka

- [1] Breiman, L. 2001. Random Forests. *Machine Learning*, 45(1): 5–32.
- [2] World Health Organization. 2006. WHO Child Growth Standards: Length/height-for-age. Geneva: WHO.
- [3] Kementerian Kesehatan RI. 2023. Survei Kesehatan Indonesia (SKI) 2023: Hasil Status Gizi Balita. Jakarta: Badan Kebijakan Pembangunan Kesehatan.
- [4] Kementerian Kesehatan RI. 2018. Riset Kesehatan Dasar (Riskesdas) 2018. Jakarta: Balitbangkes.
- [5] Pemerintah Republik Indonesia. 2021. Peraturan Presiden No. 72 Tahun 2021 tentang Percepatan Penurunan Stunting. Jakarta.

- [6] Apriluana, G. dan Fikawati, S. 2018. Analisis Faktor Risiko terhadap Kejadian Stunting pada Balita. *Media Litbangkes*, 28(4): 247–256.
- [7] World Bank. 2018. *Tackling Indonesia's Stunting: Investing in the Early Years*. Jakarta: World Bank.
- [8] Rendi Putra. 2023. Stunting Toddler (Balita) Detection Dataset. Kaggle. URL: <https://www.kaggle.com/datasets/rendiputra/stunting-balita-detection-121k-rows> (diakses 2026).
- [9] ONNX Runtime Developers. 2024. ONNX Runtime Web. URL: <https://onnxruntime.ai/> (diakses 2026).